

Resumen Ejecutivo

Este informe documenta el proceso ETL aplicado al estudio descriptivo de desigualdad territorial en la Provincia de Santiago, integrando cuatro fuentes públicas sobre áreas verdes comunales, pobreza por ingresos, capacidad municipal e información poblacional. La integración se resolvió sobre la llave `codigo_comuna`, debido a que los nombres de comuna difieren entre fuentes en mayúsculas, tildes y estilo de escritura. El repositorio evidencia un flujo reproducible desde perfilado y homologación hasta transformación, integración, validación final, carga a SQLite y análisis exploratorio.

El producto integrado observado en el repositorio corresponde a `data/processed/desigualdad_comuna` con 32 filas y 12 columnas, una fila por comuna y cobertura completa de las 32 comunas del universo definido. La validación formal reporta ausencia de duplicados por `codigo_comuna`, ausencia de nulos en las columnas finales, convertibilidad numérica sin errores, rangos consistentes para pobreza, áreas verdes e IPP, y ausencia de infinitos en las métricas derivadas por habitante. La carga final en `db/lab1_desigualdad.sqlite` materializa tres tablas: `dim_comuna` (32 filas), `fact_desigualdad_comunal` (32 filas) y `metadata_fuentes` (4 filas), con `PRAGMA quick_check = ok`.

En los outputs de Fase 9 se observan, entre otros resultados descriptivos, menores disponibilidades relativas de áreas verdes en CONCHALI, CERRILLOS, INDEPENDENCIA, LA CISTERNA, SAN MIGUEL; mayores niveles observados de pobreza por ingresos en LA PINTANA, SAN RAMON, LO ESPEJO, EL BOSQUE, CONCHALI; y menores niveles de IPP por habitante en CERRO NAVIA, LA PINTANA, LO PRADO, EL BOSQUE, LA GRANJA. El cruce por quintiles identifica rezago crítico en al menos dos dimensiones para LO ESPEJO, EL BOSQUE, CONCHALI, LA PINTANA, SAN RAMON, LA GRANJA, CERRO NAVIA. Además, Quilicura aparece como outlier plausible en `areas_verdes_m2_hab` con 3931.614773, muy por encima del siguiente valor observado en La Reina (21.734172), razón por la cual el scatter de pobreza y áreas verdes se documenta con escala logarítmica en el eje X. En conjunto, el dataset final y la base SQLite quedan listos como productos reutilizables para consulta, auditoría metodológica y montaje posterior del informe en el template externo.

Capítulo 1

Introducción

El problema abordado en este laboratorio corresponde a la descripción comparativa de desigualdad territorial entre comunas de la Provincia de Santiago, usando tres dimensiones sustantivas: disponibilidad de áreas verdes, pobreza por ingresos y capacidad municipal. La unidad de análisis observada en el proyecto es comunal, por lo que cada registro final representa una comuna y resume variables provenientes de distintas instituciones públicas.

La construcción de un proceso ETL resulta necesaria porque las fuentes disponibles no llegan en un formato analítico homogéneo. En el repositorio se observan diferencias de formato de archivo, estructuras de encabezado, escalas de medición y variantes ortográficas en `nombre_comuna`. En particular, dos fuentes SINIM fueron publicadas como archivos con extensión `.xls` pero estructura SpreadsheetML/XML 2003, mientras que las otras dos corresponden a libros `.xlsx`. Adicionalmente, los nombres comunales cambian entre mayúsculas, tildes y escritura capitalizada, lo que vuelve insuficiente cualquier integración basada en nombre crudo.

El enfoque ETL implementado en el proyecto separa explícitamente las etapas de perfilado, homologación, extracción a staging, transformación por fuente, integración final, validación estructural, carga a SQLite y análisis exploratorio. Esta secuencia permite preservar trazabilidad entre insumos y resultados, registrar decisiones metodológicas y documentar de manera reproducible cómo una combinación de fuentes heterogéneas se transforma en un dataset comunal consistente.

El proyecto integra múltiples fuentes públicas porque ninguna de ellas contiene por sí sola la unidad analítica final requerida. La población comunal provee el denominador para indicadores por habitante, la pobreza por ingresos aporta una dimensión socioeconómica, las áreas verdes entregan una dimensión territorial y los ingresos propios permanentes aportan una aproximación a capacidad municipal. El valor del producto final no reside en inferir relaciones causales, sino en dejar una base integrada, consistente y consultable para describir desigualdades comunales observadas.

Capítulo 2

Objetivos

2.1. Objetivo general

Construir y documentar un proceso ETL reproducible que integre fuentes públicas sobre áreas verdes, pobreza por ingresos, capacidad municipal y población comunal, con el fin de generar un dataset final por comuna para la Provincia de Santiago y una base SQLite apta para consulta y análisis descriptivo.

2.2. Objetivos específicos

- Verificar la estructura base del repositorio, las rutas críticas y el contrato operativo de lectura de las fuentes.
- Perfilar las cuatro fuentes reales, identificar conflictos de estructura y registrar diferencias relevantes para la integración.
- Validar la dimensión maestra de comunas y resolver la homologación reproducible con `codigo_comuna` como llave principal.
- Generar artefactos staging por fuente con selección de columnas, tipificación, filtrado territorial y estandarización comunal.
- Integrar el dataset final comunal con métricas derivadas por habitante y años de referencia explícitos.
- Validar formalmente el dataset final y cargarlo a una base SQLite con estructura consultable.
- Producir rankings, cruces descriptivos y figuras analíticas reutilizables para comunicación de resultados.

Capítulo 3

Alcance y Decisiones Metodológicas

3.1. Alcance analítico

La implementación observada en el repositorio trabaja con una unidad de análisis comunal: una fila del dataset final corresponde a una comuna. El universo final se restringe a la Provincia de Santiago y se valida contra `data/raw/dim_comuna_base.csv`, que contiene 32 comunas. El producto integrado resultante mantiene esa cobertura sin faltantes ni extras.

El análisis tiene naturaleza comparativa y descriptiva. En consecuencia, los outputs de Fase 9 se interpretan como patrones observados entre comunas y no como evidencia para inferir relaciones causales. Este criterio aparece de manera consistente en la documentación del repositorio y en los reportes analíticos.

3.2. Corte temporal y consistencia de referencia

El proyecto no fuerza una homogeneización artificial de años entre fuentes. En el dataset final quedan registrados explícitamente `anio_poblacion = 2024`, `anio_pobreza = 2022`, `anio_areas_verdes = 2024` y `anio_ingresos = 2024`. Esta decisión preserva trazabilidad respecto del origen de cada variable y evita ocultar diferencias temporales entre insumos.

3.3. Llave principal y producto final

La llave principal obligatoria del proyecto es `codigo_comuna`. `nombre_comuna` se mantiene como apoyo descriptivo y de verificación, pero no se usa como llave de integración. El producto final observado se compone de un CSV integrado con 32 filas y 12 columnas, una base SQLite con tres tablas y un conjunto de outputs de validación y análisis exploratorio.

3.4. Síntesis de decisiones

Cuadro 3.1: Decisiones metodológicas observadas en el repositorio.

Dimensión	Decisión observada	Evidencia principal
Unidad de análisis	Una fila = una comuna	README.md; outputs/resumen_dataset_final.md
Cobertura territorial	Provincia de Santiago, 32 comunas	data/raw/dim_comuna_base.csv; outputs/reporte_validacion_final.md
Llave principal	codigo_comuna	outputs/resumen_homologacion.md; src/comunas.py
Naturaleza analítica	Comparativa y descriptiva, no causal	README.md; outputs/analisis_exploratorio.md
Temporalidad	Pobreza 2022; población, áreas verdes e IPP 2024	data/raw/metadata_fuentes.csv; outputs/resumen_dataset_final.md
Integración	Merges left con validación one_to_one sobre codigo_comuna	outputs/log_integracion.md; src/integrate.py
Tratamiento de faltantes	Sin imputación; métricas derivadas quedan NA solo si la división es inválida	outputs/resumen_dataset_final.md; src/integrate.py
Producto final	CSV final, SQLite y outputs analíticos reproducibles	README.md; outputs/reporte_carga_sqlite.md

Capítulo 4

Descripción de Fuentes

Las fuentes primarias del proyecto se documentan en `data/raw/metadata_fuentes.csv`, archivo que opera como contrato de lectura para fases posteriores. Sobre esa base se distinguen cuatro insumos oficiales y versionados dentro del repositorio.

Cuadro 4.1: Resumen de fuentes primarias utilizadas en el ETL.

ID	Fuente	Institución	Año	Formato	Archivo origen	Variable principal
A	SINIM - Areas Verdes	SINIM	2024	xls (SpreadsheetML/Excel 2003)	data/raw/datos_municipales_2026040222841_Sin-Corrección-Monetaria.xls	areas_verdes_m2
B	SINIM - Capacidad Municipal	SINIM	2024	xls (SpreadsheetML/Excel 2003)	data/raw/datos_municipales_20260402223904_Sin-Corrección-Monetaria.xls	capacidad_municipal
C	Observatorio Social - Pobreza por Ingresos	Ministerio de Desarrollo Social y Familia	2022	xlsx	data/raw/estimaciones_tasas_pob_pobreza_por_ingresos_por_sector	pob_pobreza_por_ingresos_por_sector
D	Censo 2024 - Poblacion Comunal	INE	2024	xlsx	data/raw/D1_Poblacion-censada-por-sexo-y-edad-en-grupos-quinquenales.xlsx	poblacion

4.1. SINIM - Áreas verdes

Esta fuente se almacena en `data/raw/datos_municipales_2026040222841_Sin-Corrección-Monetaria.xls`. Aunque usa extensión `.xls`, la metadata y el código de extracción la tratan como `SpreadsheetML/XML 2003`. El archivo se lee en la hoja `Hoja1` con `skiprows = 2`. Su variable principal no está disponible como columna única de salida; el valor final `areas_verdes_m2` se construye combinando `mmpqc_2024` y `mmpzc_2024`.

4.2. SINIM - Capacidad municipal

La fuente de capacidad municipal se almacena en `data/raw/datos_municipales_20260402223904_Sin-Corrección-Monetaria.xls`. Al igual que la fuente anterior, se lee como `SpreadsheetML/XML 2003` desde `Hoja1` con

`skiprows = 2`. La variable comunal utilizada es `iadm41_2024`, que luego se renombra a `ipp_miles_pesos` y se conserva en miles de pesos nominales 2024.

4.3. Observatorio Social - Pobreza por ingresos

La fuente de pobreza corresponde a `data/raw/estimaciones_tasa_pobreza_ingresos_comunas_2022`. La metadata registra lectura directa con `pandas.read_excel()`, hoja `Estimaciones` y `skiprows = 2`. La columna utilizada es `Porcentaje de personas en situación de pobreza por ingresos 2022`. La propia metadata advierte que esta variable viene en escala 0–1, por lo que en transformación se convierte a porcentaje 0–100.

4.4. Censo 2024 - Población comunal

La población comunal se toma desde `data/raw/D1_Poblacion-censada-por-sexo-y-edad-en-grupos`. La hoja operativa es 2 con `skiprows = 3`. Aunque la fuente incluye columnas adicionales de sexo y razón hombre-mujer, en esta fase solo se conserva `Población censada`, ya que el objetivo del ETL es disponer de un denominador comunal consistente para indicadores por habitante.

Capítulo 5

Perfilado y Diagnóstico de Datos

El perfilado real de las fuentes quedó registrado en `outputs/perfilado_fuentes.xlsx`, con una hoja `resumen` y una hoja `columns`. Ese workbook, complementado por `outputs/conflictos_fuentes` permite documentar estructura, problemas de calidad y conflictos de integración antes de cualquier carga a staging.

5.1. Estructura observada

Las fuentes A y B presentan 52 filas con 4 y 3 columnas útiles, respectivamente. Las fuentes C y D contienen 351 y 349 filas, con 10 columnas cada una en la lectura inicial. En las cuatro fuentes no se detectaron filas duplicadas completas durante el perfilado, pero sí diferencias importantes de alcance territorial y de estructura de encabezado.

Cuadro 5.1: Perfilado resumido de las cuatro fuentes según el workbook de Fase 2.

ID	Fuente	Filas	Cols.	Dup.	Filas nulas	Formato y parser
A	SINIM - Areas Verdes	52	4	0	0	xls (SpreadsheetML/XML Excel 2003) / spreadsheetml_xml_2003
B	SINIM - Capacidad Municipal	52	3	0	0	xls (SpreadsheetML/XML Excel 2003) / spreadsheetml_xml_2003
C	Observatorio Social - Pobreza por Ingresos	351	10	0	1	xlsx / pandas_read_excel
D	Censo 2024 - Poblacion Comunal	349	10	0	1	xlsx / pandas_read_excel

5.2. Problemas de calidad y heterogeneidad

El diagnóstico registra cuatro grupos de problemas relevantes. Primero, las dos fuentes SINIM requieren parser especial porque el archivo corresponde a SpreadsheetML/XML 2003 y trae encabezados extendidos previos a la tabla útil. Segundo, todas las fuentes exceden el universo final de la Provincia de Santiago, por lo que debieron filtrarse contra la dimensión

maestra comunal. Tercero, los nombres de comuna difieren de la base maestra por tildes, mayúsculas y escritura capitalizada. Cuarto, algunas variables exigieron limpieza o reinterpretación semántica antes de integrarse.

En la fuente de áreas verdes se detectaron valores especiales **No Aplica** y **No Recepcionado**. En pobreza se identificaron seis filas de nota o blanco y una variable reportada originalmente como proporción 0–1. En población se identificaron dos filas no comunales y una fila agregada **País**, que no corresponde a la unidad analítica final.

5.3. Conflictos de integración

Cuadro 5.2: Conflictos de integración identificados durante el perfilado y la homologación.

ID	Fuente	Códigos válidos	En universo	Fuera de alcance	Dif. nombre	Observación
A	SINIM - Areas Verdes	52	32	20	6	Valores especiales No Aplica y No Recepcionado; encabezado extendido.
B	SINIM - Capacidad Municipal	52	32	20	6	Encabezado extendido y diferencias ortográficas en nombres.
C	Observatorio Social - Pobreza por Ingresos	345	32	313	32	Seis filas de nota o blanco; pobreza reportada como proporción 0-1.
D	Censo 2024 - Poblacion Comunal	347	32	315	32	Fila País y dos filas no comunales; columnas extra de sexo.

El detalle fino de columnas, tipos, nulos y muestras textuales queda respaldado por el workbook de perfilado y no se replica completo en el cuerpo principal del informe para evitar redundancia. Ese detalle se remite a anexos y a los outputs técnicos del repositorio.

Capítulo 6

Estandarización de la Llave Maestra Comunal

6.1. Criterio de llave principal

El proyecto resuelve la integración por `codigo_comuna`. Esta decisión se sustenta en evidencia directa de las fuentes: los nombres de comuna cambian entre escritura completamente en mayúsculas, escritura capitalizada y variantes con o sin tildes. Por esa razón, `nombre_comuna` se mantiene como apoyo descriptivo y de verificación, pero no como llave de merge.

6.2. Base maestra y universo final

La base maestra se encuentra en `data/raw/dim_comuna_base.csv`. El reporte de homologación confirma 32 filas, unicidad de `codigo_comuna` y `nombre_comuna`, provincia única SANTIAGO y región única METROPOLITANA DE SANTIAGO. Ese archivo define el universo final del proyecto y se utiliza para acotar cobertura durante transformación e integración.

6.3. Resultados de homologación

Dentro del universo final, las fuentes A y B presentan 26 coincidencias exactas y 6 coincidencias resueltas por normalización. Las fuentes C y D presentan 32 coincidencias resueltas por normalización y no dejan pendientes manuales para las comunas de interés. En todos los casos, el criterio operativo es filtrar por `codigo_comuna` y luego sobrescribir `nombre_comuna` con la versión estandarizada de la dimensión maestra.

Cuadro 6.1: Resumen por fuente de la homologación dentro del universo final.

Fuente	Exactas	Por normalización	Manual	Pendientes
A	26	6	0	0
B	26	6	0	0
C	0	32	0	0
D	0	32	0	0

6.4. Ejemplos reales

Cuadro 6.2: Ejemplos reales de homologación resuelta por normalización automática.

Fuente	Código	Nombre base	Nombre observado	Resolución
A	13104	CONCHALI	CONCHALÍ	coincidencia por normaliza- cion
A	13106	ESTACION CEN- TRAL	ESTACIÓN CEN- TRAL	coincidencia por normaliza- cion
A	13119	MAIPU	MAIPÚ	coincidencia por normaliza- cion
A	13122	PEÑALOLEN	PEÑALOLÉN	coincidencia por normaliza- cion
A	13129	SAN JOAQUIN	SAN JOAQUÍN	coincidencia por normaliza- cion
A	13131	SAN RAMON	SAN RAMÓN	coincidencia por normaliza- cion
B	13104	CONCHALI	CONCHALÍ	coincidencia por normaliza- cion
B	13106	ESTACION CEN- TRAL	ESTACIÓN CEN- TRAL	coincidencia por normaliza- cion

6.5. Controles de unicidad y cobertura

La homologación no deja casos pendientes dentro de las 32 comunas del proyecto. El dataset final validado conserva una sola fila por `codigo_comuna`, sin faltantes ni extras respecto a `dim_comuna_base.csv`. Esta consistencia se vuelve a confirmar en la validación final y en la carga a SQLite.

Capítulo 7

Modelo de Datos

Esta sección describe el modelo tal como existe en `db/lab1_desigualdad.sqlite`. No se corrige ni reinterpreta el diseño observado; se documenta su implementación real. El modelo responde a una lógica dimensión-hecho complementada por una tabla de metadata.

Cuadro 7.1: Resumen del modelo físico observado en SQLite.

Tabla	Rol	Llave primaria	Cols.	Filas	Observación
dim_comuna	Dimensión de comunas del universo final.	codigo_comuna	5	32	Conserva nombre, provincia, región y fuente_referencia.
fact_desigualdad_comunal	Tabla de hechos con variables finales y métricas derivadas.	codigo_comuna	11	32	No replica nombre_comuna; se relaciona con dim_comuna.
metadata_fuentes	Contrato operativo y trazabilidad de lectura de fuentes.	id_fuente	13	4	Documenta institución, URL, hoja, skiprows y archivo lógico.

7.1. Tabla dim_comuna

La dimensión comunal contiene 32 filas y cinco columnas: `codigo_comuna`, `nombre_comuna`, `provincia`, `region` y `fuentes_referencia`. Esta tabla preserva la identificación y el contexto territorial del universo final.

7.2. Tabla fact_desigualdad_comunal

La tabla de hechos contiene 32 filas y once columnas. Su llave es `codigo_comuna` y almacena `poblacion`, `anio_poblacion`, `pobreza_ingresos_pct`, `anio_pobreza`, `areas_verdes_m2`, `anio_areas_verdes`, `ipp_miles_pesos`, `anio_ingresos`, `areas_verdes_m2_hab` e `ipp_pesos_hab`. El campo `nombre_comuna` no se replica en esta tabla; se obtiene mediante unión con `dim_comuna`.

7.3. Tabla `metadata_fuentes`

La tabla `metadata_fuentes` contiene 4 filas y trece columnas. Su función es conservar la trazabilidad operativa de las fuentes: institución, URL, fecha de descarga, formato, año de referencia, hoja, `skiprows`, archivo lógico y observaciones. Esta tabla conecta el resultado analítico con el contrato de lectura real del ETL.

7.4. Relación entre tablas

El vínculo entre la dimensión y la tabla de hechos se realiza por `codigo_comuna`. En términos operativos, la combinación `dim_comuna` + `fact_desigualdad_comunal` reproduce el dataset final validado, mientras que `metadata_fuentes` documenta el origen de los insumos y las reglas mínimas de lectura.

Capítulo 8

Mapa Lógico de Datos

El mapa lógico resume cómo los datos transitan desde archivos raw heterogéneos hasta variables finales listas para validación, persistencia y análisis. En este proyecto, la secuencia observable es: contrato de lectura en metadata, lectura real por fuente, staging por fuente, integración sobre dimensión maestra, métricas derivadas y persistencia final en CSV y SQLite.

Cuadro 8.1: Mapa lógico resumido desde origen hasta variable final.

Fase/fuente	Origen	Transformación	Destino final
Todas	codigo_comuna / Código	Parseo numérico y formateo string de 5 dígitos	codigo_comuna
A	mmpqc_2024 + mmpzc_2024	No Aplica ->0; No Recepcionado ->NA; suma con min_count=2	areas_verdes_m2
B	iadm41_2024	Renombre y conservación en miles de pesos nominales 2024	ipp_miles_pesos
C	Porcentaje de personas en situación de pobreza por ingresos 2022	Conversión de proporción 0-1 a porcentaje 0-100 y redondeo	pobreza_ingresos_pct
D	Población censada	Selección, tipificación Int64 y filtrado por universo	poblacion
Fase 6	Constantes de referencia	Asignación explícita de años de referencia por variable	anio_poblacion / anio_pobreza / anio_areas_verdes / anio_ingresos
Fase 6	areas_verdes_m2 + poblacion	División controlada con población >0	areas_verdes_m2_hab
Fase 6	ipp_miles_pesos + poblacion	Conversión a pesos por habitante y control de infinitos	ipp_pesos_hab

El flujo anterior muestra dos criterios centrales. Primero, las variables finales solo se construyen a partir de campos realmente presentes en las fuentes y en los artefactos staging. Segundo, cualquier transformación semántica relevante queda documentada en el código y en los reportes de salida, por ejemplo la conversión de pobreza desde proporción a porcentaje o la suma de componentes de áreas verdes para producir `areas_verdes_m2`.

El detalle extendido de artefactos y destinos se deja en anexos para facilitar trazabilidad técnica sin sobrecargar el cuerpo principal del informe.

Capítulo 9

Desarrollo del ETL

9.1. Extracción

La extracción se coordina desde `src/main.py` y `src/extract.py`. El proceso usa `data/raw/metadata_f` como contrato operativo para ubicar archivo, hoja, `skiprows`, formato y observaciones por fuente. Las fuentes A y B se leen mediante un parser específico para SpreadsheetML/XML 2003, mientras que las fuentes C y D se leen con `pandas.read_excel()` respetando la configuración registrada en metadata.

El resultado de esta etapa no es solo la lectura en memoria, sino también la generación de evidencia diagnóstica en `outputs/perfilado_fuentes.xlsx` y `outputs/conflictos_fuentes.md`. Esto permite detectar estructura real, filas fuera de alcance, valores especiales y heterogeneidad en nombres comunales antes de construir los staging.

9.2. Transformación

La transformación se implementa en `src/transform.py`. Cada fuente produce un staging independiente y validado. Las reglas aplicadas incluyen selección de columnas, renombre semántico, tipificación, formateo de `codigo_comuna`, estandarización de `nombre_comuna`, tratamiento de valores especiales, filtrado al universo final de 32 comunas y validaciones de rango.

9.3. Integración

La integración se implementa en `src/integrate.py`. El proceso parte desde `dim_comuna_base.csv` y ejecuta cuatro merges `left` con validación `one_to_one`, en el orden población, pobreza, áreas verdes y capacidad municipal. Después del merge se asignan los años de referencia por variable y se calculan las métricas derivadas `areas_verdes_m2_hab` e `ipp_pesos_hab`, controlando divisiones inválidas e infinitos.

El flujo completo puede reejecutarse desde la raíz del repositorio con `python src/main.py` o `python -m src.main`. Los reportes `outputs/log_integracion.md`, `outputs/resumen_dataset_final.md` y `outputs/reporte_correcciones_pre_fase10.md` respaldan tanto la lógica del merge como la reproducibilidad observada del pipeline.

Cuadro 9.1: Transformaciones y controles relevantes observados en el ETL.

Transformación	Fuente	Regla aplicada	Evidencia
Selección de columnas	A-D	Solo se conservan campos comunales y variables de interés.	outputs/resumen_transformaciones.md
Normalización comunal	A-D	Estandarización de nombre_comuna contra dim_comuna_base.csv.	outputs/resumen_transformaciones.md;
Formateo de llave	A-D	codigo_comuna se tipifica y luego se fija como string de 5 dígitos.	out-puts/homologacion_comunas.csv
Tratamiento de valores especiales	A	No Aplica ->0 y No Recepcionado ->NA en componentes de áreas verdes.	src/transform.py
Conversión de escala	C	La pobreza se transforma desde proporción 0-1 a porcentaje 0-100.	outputs/conflictos_fuentes.md;
Filtrado territorial	A-D	Se excluyen comunas fuera de la Provincia de Santiago y filas sin código válido.	src/transform.py
Renombre semántico	B-D	iadm41_2024 ->ipp_miles_pesos; Población censada ->poblacion.	data/raw/metadata_fuentes.csv;
Métricas derivadas	Fase 6	Se calculan areas_verdes_m2_hab e ipp_pesos_hab con control de población >0.	src/transform.py
Validaciones de rango	A-D	Población >0; pobreza 0-100; áreas verdes e IPP no negativos.	outputs/resumen_dataset_final.md;
Control de cardinalidad	Fase 6	Todos los merges se ejecutan como left con validación one_to_one.	src/integrate.py

Capítulo 10

Validación del Dataset Final

La validación formal del dataset final quedó documentada en `outputs/reporte_validacion_final.csv` y `outputs/reporte_validacion_final.md`. El archivo validado es `data/processed/desigualdad_comuna` con 32 filas y 12 columnas.

Cuadro 10.1: Resumen de validaciones estructurales y de rango del dataset final.

Check	Descripción	Resultado	Valor observado	Detalle
<code>fila_por_comuna</code>	Existe una sola fila por comuna.	OK	<code>filas=32;</code> <code>comunas_unicas=32</code>	Sin multiplicacion de filas por comuna.
<code>codigo_comuna_unico</code>	<code>codigo_comuna</code> es unico.	OK	0	Sin duplicados por llave.
<code>cantidad_comunas</code>	El dataset final contiene exactamente 32 comunas.	OK	32	Cobertura total observada.
<code>cobertura_dim_base</code>	La cobertura comunal coincide con <code>'dim_comuna_base.csv'</code> .	OK	<code>faltantes=[];</code> <code>extras=[]</code>	Cobertura exacta contra la base maestra.
<code>convertibilidad_numericas</code>	Todas las columnas numericas son convertibles a tipo numerico razonable.	OK	<code>poblacion=0;</code> <code>anio_poblacion=0;</code> <code>pobreza_ingresos_pct=0;</code> <code>anio_pobreza=0;</code> <code>areas_verdes_m2=0;</code> <code>anio_areas_verdes=0;</code> <code>ipp_miles_pesos=0;</code> <code>anio_ingresos=0;</code> <code>areas_verdes_m2_hab=0;</code> <code>ipp_pesos_hab=0</code>	Todas las columnas numericas son convertibles.
<code>poblacion_positiva</code>	<code>'poblacion'</code> es estrictamente mayor que 0.	OK	0	Toda la poblacion es positiva.
<code>pobreza_rango</code>	<code>'pobreza_ingresos_pct'</code> queda entre 0 y 100 cuando hay dato.	OK	0	La variable de pobreza esta dentro de rango.
<code>areas_verdes_no_negativas</code>	<code>'areas_verdes_m2'</code> es no negativa cuando hay dato.	OK	0	Sin areas verdes negativas.
<code>ipp_no_negativo</code>	<code>'ipp_miles_pesos'</code> es no negativo cuando hay dato.	OK	0	Sin IPP negativos.
<code>areas_verdes_m2_hab_sin_infinitos</code>	<code>'areas_verdes_m2_hab'</code> no contiene infinitos.	OK	0	Sin infinitos en areas verdes por habitante.
<code>ipp_pesos_hab_sin_infinitos</code>	<code>'ipp_pesos_hab'</code> no contiene infinitos.	OK	0	Sin infinitos en IPP por habitante.
<code>apto_para_sqlite</code>	El dataset final es apto para pasar a Fase 8 / carga a SQLite.	OK	APTO	El dataset final cumple los criterios estructurales y de integridad requeridos.

Los chequeos reportados confirman una fila por comuna, unicidad de `codigo_comuna`, formato de llave consistente de cinco dígitos, cobertura exacta respecto de la dimensión maestra y coincidencia de `nombre_comuna` con `dim_comuna_base.csv`. También se informa convertibilidad numérica sin errores para todas las columnas cuantitativas, nulos igual a cero

en las doce columnas finales y años de referencia consistentes con la fase de integración.

Desde el punto de vista de reglas de negocio mínimas, la validación confirma **poblacion** >0, **pobreza_ingresos_pct** entre 0 y 100, ausencia de áreas verdes negativas, ausencia de IPP negativos y ausencia de infinitos en las métricas derivadas por habitante. Sobre esa base, el propio reporte marca el dataset como apto para la fase de carga a SQLite.

Capítulo 11

Carga Final a SQLite

La persistencia final del proyecto se materializa en `db/lab1_desigualdad.sqlite`. En términos operativos, esta elección deja un artefacto local único, consultable con SQL y suficiente para validar consistencia entre dimensión, tabla de hechos y metadata sin depender de un servidor externo.

11.1. Estructura y conteos

La base resultante contiene las tablas `dim_comuna`, `fact_desigualdad_comunal` y `metadata_fuentes`. El reporte de carga y la inspección directa de la base coinciden en los conteos observados.

Cuadro 11.1: Conteo de filas por tabla en la base SQLite final.

Tabla	Filas	Rol
<code>dim_comuna</code>	32	Dimensión comunal
<code>fact_desigualdad_comunal</code>	32	Tabla de hechos
<code>metadata_fuentes</code>	4	Contrato operativo de fuentes

11.2. Integridad básica

El archivo abre correctamente y el chequeo `PRAGMA quick_check` devuelve `ok`. Además, los reportes de carga informan ausencia de duplicados por `codigo_comuna` en la dimensión y en la tabla de hechos, y ausencia de códigos huérfanos entre ambas tablas.

11.3. Consultas de prueba

Las consultas documentadas tras la carga reproducen conteos por tabla y rankings básicos para áreas verdes, pobreza e IPP. Esto confirma que la base queda utilizable no solo como respaldo del dataset final, sino también como soporte de consulta analítica.

En síntesis, la carga final reproduce el resultado del ETL sin alterar la centralidad de `codigo_comuna`. `dim_comuna` conserva los descriptores territoriales, `fact_desigualdad_comunal`

Cuadro 11.2: Consultas de prueba documentadas tras la carga en SQLite.

Consulta	Ord.	Tabla	Código	Comuna	Valor	Detalle
conteo_filas_por_tabla	-	dim_comuna	-	-	32.0	conteo de filas
conteo_filas_por_tabla	-	fact_desigualdad_comunal	-	-	32.0	conteo de filas
conteo_filas_por_tabla	-	metadata_fuentes	-	-	4.0	conteo de filas
top_5_menor_areas_verdes_m2_ha	1	fact_desigualdad_comunal	13104	CONCHALI	0.603247	areas_verdes_m2_ha
top_5_menor_areas_verdes_m2_ha	2	fact_desigualdad_comunal	13102	CERRILLOS	0.878035	areas_verdes_m2_ha
top_5_menor_areas_verdes_m2_ha	3	fact_desigualdad_comunal	13108	INDEPENDENCIA	0.878941	areas_verdes_m2_ha
top_5_menor_areas_verdes_m2_ha	4	fact_desigualdad_comunal	13109	LA CISTERNA	0.904776	areas_verdes_m2_ha
top_5_menor_areas_verdes_m2_ha	5	fact_desigualdad_comunal	13130	SAN MIGUEL	1.154347	areas_verdes_m2_ha
top_5_mayor_pobreza_ingresos_pct	1	fact_desigualdad_comunal	13112	LA PINTANA	9.2938	pobreza_ingresos_pct
top_5_mayor_pobreza_ingresos_pct	2	fact_desigualdad_comunal	13131	SAN RAMON	6.8821	pobreza_ingresos_pct
top_5_mayor_pobreza_ingresos_pct	3	fact_desigualdad_comunal	13116	LO ESPEJO	6.7817	pobreza_ingresos_pct
top_5_mayor_pobreza_ingresos_pct	4	fact_desigualdad_comunal	13105	EL BOSQUE	6.1982	pobreza_ingresos_pct
top_5_mayor_pobreza_ingresos_pct	5	fact_desigualdad_comunal	13104	CONCHALI	6.0799	pobreza_ingresos_pct
top_5_menor_ipp_pesos_hab	1	fact_desigualdad_comunal	13103	CERRO NAVIA	27701.980354	ipp_pesos_hab
top_5_menor_ipp_pesos_hab	2	fact_desigualdad_comunal	13112	LA PINTANA	38281.739358	ipp_pesos_hab
top_5_menor_ipp_pesos_hab	3	fact_desigualdad_comunal	13117	LO PRADO	39312.805346	ipp_pesos_hab
top_5_menor_ipp_pesos_hab	4	fact_desigualdad_comunal	13105	EL BOSQUE	45941.619379	ipp_pesos_hab
top_5_menor_ipp_pesos_hab	5	fact_desigualdad_comunal	13111	LA GRANJA	47063.353627	ipp_pesos_hab

concentra las variables finales cuantitativas y `metadata_fuentes` mantiene la trazabilidad del proceso de lectura.

Capítulo 12

Resultados y Análisis Exploratorio

Esta sección se apoya en `outputs/analisis_exploratorio.md`, `outputs/tablas_hallazgos_fase9.csv`, los rankings exportados y las figuras generadas en Fase 9. La lectura se mantiene en un plano estrictamente descriptivo.

12.1. Rankings por dimensión

Los menores valores observados de `areas_verdes_m2_hab` corresponden a CONCHALI, CERRILLOS, INDEPENDENCIA, LA CISTERNA, SAN MIGUEL. En pobreza por ingresos, los mayores valores observados corresponden a LA PINTANA, SAN RAMON, LO ESPEJO, EL BOSQUE, CONCHALI. En `ipp_pesos_hab`, los menores valores observados corresponden a CERRO NAVIA, LA PINTANA, LO PRADO, EL BOSQUE, LA GRANJA.

Cuadro 12.1: Resumen de hallazgos descriptivos reutilizables desde los outputs de Fase 9.

Hallazgo	Comunas observadas	Output fuente
Menor áreas verdes por habitante	CONCHALI, CERRILLOS, INDEPENDENCIA, LA CISTERNA, SAN MIGUEL	outputs/ranking_areas_verdes.csv
Mayor pobreza por ingresos	LA PINTANA, SAN RAMON, LO ESPEJO, EL BOSQUE, CONCHALI	outputs/ranking_pobreza.csv
Menor IPP por habitante	CERRO NAVIA, LA PINTANA, LO PRADO, EL BOSQUE, LA GRANJA	outputs/ranking_ipp.csv
Peor quintil simultáneo de pobreza y áreas verdes	CONCHALI	outputs/tablas_hallazgos_fase9.csv
Peor quintil simultáneo de pobreza e IPP	LA PINTANA, SAN RAMON, LO ESPEJO, EL BOSQUE, LA GRANJA, CERRO NAVIA	outputs/tablas_hallazgos_fase9.csv
Rezago crítico en al menos dos dimensiones	LO ESPEJO, EL BOSQUE, CONCHALI, LA PINTANA, SAN RAMON, LA GRANJA, CERRO NAVIA	outputs/indice_rezago_territorial.csv




Figura 12.1: Diez comunas con menor disponibilidad de áreas verdes por habitante.




Figura 12.2: Diez comunas con mayor pobreza por ingresos en el dataset final.




Figura 12.3: Diez comunas con menor IPP por habitante en el dataset final.

12.2. Cruces descriptivos y rezago en múltiples dimensiones

El cruce por quintiles muestra que el peor quintil simultáneo de pobreza y áreas verdes por habitante se observa en CONCHALI. Por su parte, el peor quintil simultáneo de pobreza e IPP por habitante se observa en LA PINTANA, SAN RAMON, LO ESPEJO, EL BOSQUE, LA GRANJA, CERRO NAVIA. Al ampliar la mirada a rezago crítico en al menos dos dimensiones, aparecen LO ESPEJO, EL BOSQUE, CONCHALI, LA PINTANA, SAN RAMON, LA GRANJA, CERRO NAVIA.

El índice auxiliar de rezago territorial, definido en Fase 9 como suma de quintiles de rezago, ordena en los primeros lugares a Conchalí, El Bosque, Lo Espejo, La Pintana y San Ramón. Este índice se interpreta solo como apoyo descriptivo para resumir coincidencias de rezago relativo entre comunas.

Cuadro 12.2: Comunas con rezago crítico en al menos dos dimensiones del análisis auxiliar.

Código	Comuna	Pobreza	Áreas/hab	IPP/hab	Dim.	Índice
13116	LO ESPEJO	6.7817	3.344647	48908.769116	2	14
13105	EL BOSQUE	6.1982	2.780551	45941.619379	2	14
13104	CONCHALI	6.0799	0.603247	88427.175603	2	14
13112	LA PINTANA	9.2938	4.309741	38281.739358	2	13
13131	SAN RAMON	6.8821	5.256743	54032.104418	2	13
13111	LA GRANJA	6.0302	6.233793	47063.353627	2	12
13103	CERRO NAVIA	6.0135	5.851764	27701.980354	2	12




Figura 12.4: Diez comunas con mayor índice auxiliar de rezago territorial.

12.3. Lectura descriptiva del scatter y tratamiento del outlier

El scatter de pobreza y áreas verdes por habitante se mantiene como evidencia exploratoria y no como prueba de relación causal. Su lectura exige una advertencia metodológica explícita: Quilicura registra `areas_verdes_m2_hab` = 3931.614773, muy por encima de La Reina (21.734172) y Providencia (20.172865). Por esta razón, el gráfico fue documentado con escala logarítmica en el eje X para preservar visibilidad sobre el resto de las comunas.

En términos comunicacionales, el caso de Quilicura debe tratarse como outlier plausible y no como valor descartado. El repositorio no aporta evidencia para clasificarlo como error; por lo tanto, la decisión metodológica correcta es mantenerlo, advertir su influencia en la escala y evitar interpretaciones causales a partir del gráfico.




Figura 12.5: Scatter descriptivo entre pobreza por ingresos y áreas verdes por habitante.

Capítulo 13

Limitaciones

El proyecto presenta limitaciones metodológicas que deben hacerse explícitas para interpretar correctamente el dataset y los outputs analíticos.

- Las fuentes no son perfectamente homogéneas en términos temporales: pobreza por ingresos corresponde a 2022, mientras población, áreas verdes e IPP corresponden a 2024.
- El análisis es comparativo y descriptivo; no permite sostener inferencias causales entre pobreza, áreas verdes y capacidad municipal.
- El `indice_rezago_territorial` es una construcción auxiliar de Fase 9 y no una variable oficial provista por las instituciones fuente.
- Existen outliers plausibles que afectan la lectura visual, en particular Quilicura en `areas_verdes_m2_hab` y varias comunas de altos ingresos en `ipp_pesos_hab`.
- La interpretación depende de definiciones institucionales de origen, por ejemplo la forma en que cada fuente publica áreas verdes, IPP o pobreza por ingresos.
- El universo analizado se restringe a la Provincia de Santiago, por lo que el dataset final no representa al total regional ni nacional.

Estas limitaciones no invalidan el producto final, pero sí acotan su uso legítimo: comparación territorial observada, trazabilidad metodológica y reutilización del dataset integrado bajo el mismo marco descriptivo.

Capítulo 14

Conclusiones

Desde el punto de vista técnico, el repositorio documenta un proceso ETL cerrado y reproducible para integrar cuatro fuentes públicas heterogéneas bajo una llave comunal estable. La secuencia de perfilado, homologación, staging, integración, validación y carga final se encuentra respaldada por código fuente, reportes técnicos y artefactos exportados. El resultado es un dataset comunal consistente y una base SQLite consultable, sin necesidad de reinterpretar ni corregir el modelo observado.

Desde el punto de vista analítico, los outputs de Fase 9 muestran que las dimensiones incluidas no se distribuyen homogéneamente entre comunas. Se observan grupos comunales recurrentes en posiciones de rezago relativo, tanto en rankings individuales como en cruces de pobreza con áreas verdes o con IPP por habitante. Estas observaciones deben mantenerse en clave descriptiva, sin extrapolar mecanismos causales.

El valor principal del trabajo no se limita al informe. El CSV final y la base SQLite quedan disponibles como productos reutilizables para consultas, auditoría metodológica, análisis exploratorios posteriores y montaje del informe final en el template externo. En ese sentido, la Fase 10 preparada en este paquete no reemplaza el ETL, sino que lo traduce a materiales documentales trazables y listos para integración editorial.

Apéndice A

Diccionario de datos final

Este anexo resume las 12 variables que componen el dataset final integrado y deja explícito el origen de cada una.

Cuadro A.1: Diccionario resumido del dataset final integrado.

Variable	Tipo	Descripción	Origen
codigo_comuna	string(5)	Llave maestra comunal.	dim_comuna_base / todas las fuentes
nombre_comuna	string	Nombre oficial de la base maestra.	dim_comuna_base
poblacion	int	Población censada comunal.	Fuente D / Censo 2024
anio_poblacion	int	Año de referencia de población.	Constante Fase 6
pobreza_ingresos_pct	float	Porcentaje de pobreza por ingresos.	Fuente C / Observatorio Social
anio_pobreza	int	Año de referencia de pobreza.	Constante Fase 6
areas_verdes_m2	int	Superficie total de áreas verdes comunales.	Fuente A / SINIM
anio_areas_verdes	int	Año de referencia de áreas verdes.	Constante Fase 6
ipp_miles_pesos	int	Ingresos propios permanentes en miles de pesos.	Fuente B / SINIM
anio_ingresos	int	Año de referencia del IPP.	Constante Fase 6
areas_verdes_m2_hab	float	Áreas verdes por habitante.	Derivada Fase 6
ipp_pesos_hab	float	IPP en pesos por habitante.	Derivada Fase 6

Apéndice B

Perfilado extendido

El detalle extendido del perfilado se respalda en `outputs/perfilado_fuentes.xlsx`. La siguiente tabla resume la estructura observada en la etapa diagnóstica.

Cuadro B.1: Perfilado resumido de las cuatro fuentes según el workbook de Fase 2.

ID	Fuente	Filas	Cols.	Dup.	Filas nulas	Formato y parser
A	SINIM - Areas Verdes	52	4	0	0	xls (SpreadsheetML/XML Excel 2003) / spreadsheetml_xml_2003
B	SINIM - Capacidad Municipal	52	3	0	0	xls (SpreadsheetML/XML Excel 2003) / spreadsheetml_xml_2003
C	Observatorio Social - Pobreza por Ingresos	351	10	0	1	xlsx / pandas_read_excel
D	Censo 2024 - Poblacion Comunal	349	10	0	1	xlsx / pandas_read_excel

Apéndice C

Homologación de comunas

La homologación se resolvió sin pendientes manuales dentro del universo final. Se documentan a continuación el resumen por fuente y ejemplos de normalización aplicada.

Cuadro C.1: Resumen por fuente de la homologación dentro del universo final.

Fuente	Exactas	Por normalización	Manual	Pendientes
A	26	6	0	0
B	26	6	0	0
C	0	32	0	0
D	0	32	0	0

Cuadro C.2: Ejemplos reales de homologación resuelta por normalización automática.

Fuente	Código	Nombre base	Nombre observado	Resolución
A	13104	CONCHALI	CONCHALÍ	coincidencia por normalización
A	13106	ESTACION CENTRAL	ESTACIÓN CENTRAL	coincidencia por normalización
A	13119	MAIPU	MAIPÚ	coincidencia por normalización
A	13122	PEÑALOLEN	PEÑALOLÉN	coincidencia por normalización
A	13129	SAN JOAQUIN	SAN JOAQUÍN	coincidencia por normalización
A	13131	SAN RAMON	SAN RAMÓN	coincidencia por normalización
B	13104	CONCHALI	CONCHALÍ	coincidencia por normalización
B	13106	ESTACION CENTRAL	ESTACIÓN CENTRAL	coincidencia por normalización

Apéndice D

Mapa lógico extendido

Este anexo deja trazabilidad entre artefactos del ETL y sus destinos operativos.

Cuadro D.1: Mapa lógico extendido de artefactos y destinos del ETL.

Artefacto	Tipo	Contenido relevante	Fase de uso
data/raw/metadata_fuentes.csv	Contrato operativo de lectura	Define archivo, hoja, skiprows y observaciones por fuente	Fases 2 y 4
data/raw/dim_comuna_base.csv	Universo maestro	Restringe cobertura a 32 comunas y aporta nombre oficial	Fases 3, 5 y 6
data/staging/poblacion_staging.csv	Staging D	codigo_comuna, nombre_comuna, poblacion	Fase 6 / merge 1
data/staging/pobreza_staging.csv	Staging C	codigo_comuna, nombre_comuna, pobreza_ingresos_pct	Fase 6 / merge 2
data/staging/areas_verdes_staging.csv	Staging A	codigo_comuna, nombre_comuna, mmpqc_2024, mmpzc_2024, areas_verdes_m2	Fase 6 / merge 3
data/staging/ingresos_staging.csv	Staging B	codigo_comuna, nombre_comuna, ipp_miles_pesos	Fase 6 / merge 4
data/processed/desigualdad_comunal_final.csv	Dataset final	12 columnas finales y una fila por comuna	Fases 7, 8 y 9
db/lab1_desigualdad.sqlite	Persistencia final	dim_comuna, fact_desigualdad_comunal, metadata_fuentes	Fase 8

Apéndice E

Validación final del dataset

La validación de Fase 7 confirma consistencia estructural, cobertura y rangos.

Cuadro E.1: Resumen de validaciones estructurales y de rango del dataset final.

Check	Descripción	Resultado	Valor observado	Detalle
fila_por_comuna	Existe una sola fila por comuna.	OK	filas=32; comunas_unicas=32	Sin multiplicacion de filas por comuna.
codigo_comuna_unico	'codigo_comuna' es unico.	OK	0	Sin duplicados por llave.
cantidad_comunas	El dataset final contiene exactamente 32 comunas.	OK	32	Cobertura total observada.
cobertura_dim_base	La cobertura comunal coincide con 'dim_comuna_base.csv'.	OK	faltantes=[]; extras=[]	Cobertura exacta contra la base maestra.
convertibilidad_numericas	Las columnas numericas son convertibles a tipo numerico razonable.	OK	poblacion=0; anio_poblacion=0; pobreza_ingresos_pct=0; anio_pobreza=0; areas_verdes_m2=0; anio_areas_verdes=0; ipp_miles_pesos=0; anio_ingresos=0; areas_verdes_m2_hab=0; ipp_pesos_hab=0	Todas las columnas numericas son convertibles.
poblacion_positiva	'poblacion' es estrictamente mayor que 0.	OK	0	Toda la poblacion es positiva.
pobreza_rango	'pobreza_ingresos_pct' queda entre 0 y 100 cuando hay dato.	OK	0	La variable de pobreza esta dentro de rango.
areas_verdes_no_negativas	'areas_verdes_m2' es no negativa cuando hay dato.	OK	0	Sin areas verdes negativas.
ipp_no_negativo	'ipp_miles_pesos' es no negativo cuando hay dato.	OK	0	Sin IPP negativos.
areas_verdes_m2_hab_sin_infinitos	'areas_verdes_m2_hab' no contiene infinitos.	OK	0	Sin infinitos en areas verdes por habitante.
ipp_pesos_hab_sin_infinitos	'ipp_pesos_hab' no contiene infinitos.	OK	0	Sin infinitos en IPP por habitante.
apto_para_sqlite	El dataset final es apto para pasar a Fase 8 / carga a SQLite.	OK	APTO	El dataset final cumple los criterios estructurales y de integridad requeridos.

Apéndice F

Carga SQLite

Se resumen los conteos observados y las consultas de prueba utilizadas tras la carga final.

Cuadro F.1: Conteo de filas por tabla en la base SQLite final.

Tabla	Filas	Rol
dim_comuna	32	Dimensión comunal
fact_desigualdad_comunal	32	Tabla de hechos
metadata_fuentes	4	Contrato operativo de fuentes

Cuadro F.2: Consultas de prueba documentadas tras la carga en SQLite.

Consulta	Ord.	Tabla	Código	Comuna	Valor	Detalle
conteo_filas_por_tabla	-	dim_comuna	-	-	32.0	conteo de filas
conteo_filas_por_tabla	-	fact_desigualdad_comunal	-	-	32.0	conteo de filas
conteo_filas_por_tabla	-	metadata_fuentes	-	-	4.0	conteo de filas
top_5_menor_areas_verdes_m2_hab	1	fact_desigualdad_comunal	3104	CONCHALI	0.603247	areas_verdes_m2_hab
top_5_menor_areas_verdes_m2_hab	2	fact_desigualdad_comunal	3102	CERRILLOS	0.878035	areas_verdes_m2_hab
top_5_menor_areas_verdes_m2_hab	3	fact_desigualdad_comunal	3108	INDEPENDENCIA	0.878941	areas_verdes_m2_hab
top_5_menor_areas_verdes_m2_hab	4	fact_desigualdad_comunal	3109	LA CISTERNA	0.904776	areas_verdes_m2_hab
top_5_menor_areas_verdes_m2_hab	5	fact_desigualdad_comunal	3130	SAN MIGUEL	1.154347	areas_verdes_m2_hab
top_5_mayor_pobreza_ingresos_pct	1	fact_desigualdad_comunal	3112	LA PINTANA	9.2938	pobreza_ingresos_pct
top_5_mayor_pobreza_ingresos_pct	2	fact_desigualdad_comunal	3131	SAN RAMON	6.8821	pobreza_ingresos_pct
top_5_mayor_pobreza_ingresos_pct	3	fact_desigualdad_comunal	3116	LO ESPEJO	6.7817	pobreza_ingresos_pct
top_5_mayor_pobreza_ingresos_pct	4	fact_desigualdad_comunal	3105	EL BOSQUE	6.1982	pobreza_ingresos_pct
top_5_mayor_pobreza_ingresos_pct	5	fact_desigualdad_comunal	3104	CONCHALI	6.0799	pobreza_ingresos_pct
top_5_menor_ipp_pesos_hab	1	fact_desigualdad_comunal	3103	CERRO NAVIA	27701.980354	ipp_pesos_hab
top_5_menor_ipp_pesos_hab	2	fact_desigualdad_comunal	3112	LA PINTANA	38281.739358	ipp_pesos_hab
top_5_menor_ipp_pesos_hab	3	fact_desigualdad_comunal	3117	LO PRADO	39312.805346	ipp_pesos_hab
top_5_menor_ipp_pesos_hab	4	fact_desigualdad_comunal	3105	EL BOSQUE	45941.619379	ipp_pesos_hab
top_5_menor_ipp_pesos_hab	5	fact_desigualdad_comunal	3111	LA GRANJA	47063.353627	ipp_pesos_hab

Apéndice G

Revisión breve de Fase 9: outliers y comunicabilidad

La revisión corta de Fase 9 respalda tres advertencias: el índice de rezago es auxiliar, Quilicura debe tratarse como outlier plausible en áreas verdes por habitante y el scatter requiere lectura cuidadosa por su escala. Para el informe final conviene mantener estas advertencias junto a las figuras analíticas.

Cuadro G.1: Resumen de hallazgos descriptivos reutilizables desde los outputs de Fase 9.

Hallazgo	Comunas observadas	Output fuente
Menor áreas verdes por habitante	CONCHALI, CERRILLOS, INDEPENDENCIA, LA CISTERNA, SAN MIGUEL	outputs/ranking_areas_verdes.csv
Mayor pobreza por ingresos	LA PINTANA, SAN RAMON, LO ESPEJO, EL BOSQUE, CONCHALI	outputs/ranking_pobreza.csv
Menor IPP por habitante	CERRO NAVIA, LA PINTANA, LO PRADO, EL BOSQUE, LA GRANJA	outputs/ranking_ipp.csv
Peor quintil simultáneo de pobreza y áreas verdes	CONCHALI	outputs/tablas_hallazgos_fase9.csv
Peor quintil simultáneo de pobreza e IPP	LA PINTANA, SAN RAMON, LO ESPEJO, EL BOSQUE, LA GRANJA, CERRO NAVIA	outputs/tablas_hallazgos_fase9.csv
Rezago crítico en al menos dos dimensiones	LO ESPEJO, EL BOSQUE, CONCHALI, LA PINTANA, SAN RAMON, LA GRANJA, CERRO NAVIA	outputs/indice_rezago_territorial.csv